

Predição da Rugosidade Superficial do Alumínio Após Fresamento Utilizando Modelo de Inteligência Artificial baseado em Perceptrons Multicamadas (MLP)



Erick Fastera da Silva^[1], Wallace Gusmão Ferreira^[2]

Centro de Engenharia, Modelagem e Ciências Sociais Aplicadas, Universidade Federal do ABC
Av. Dos Estados, 5001 – Bangú, Santo André – SP, 09210-580
{eerick@aluno.ufabc.edu.br, wallace.ferreira@ufabc.edu.br}

Objetivos: Por meio do Machine Learning, busca-se neste trabalho obter um modelo otimizado para a previsão da rugosidade superficial média do alumínio após processamento de fresa.

INTRODUÇÃO

A predição das condições finais dos materiais após o seu processamento, como o fresamento com ponta esférica (Figura 1), é de extrema importância, dado o alto custo da realização de tais processos.




FIGURA 1: Fresamento com ponta esférica.

FONTE: WANG et al., 2017.

Assim, um modelo de Perceptron Multicamadas (MLP) do tipo regressor pode ser empregado para a predição da rugosidade superficial média do produto final do alumínio. Sua estrutura se baseia em uma camada de entrada, uma de saída e uma ou mais camadas ocultas. Seus parâmetros estão representados na Figura 2.




FIGURA 2: Perceptron Multicamadas (MLP).

MATERIAIS E MÉTODOS

Através da biblioteca Sklearn, foi utilizado 68 dados de treinamento e 16 dados de teste de HOSSAIN, 2012 para gerar o MLP. A otimização do sistema foi obtida por meio do Grid Search com a verificação de 336.960 configurações de metaparâmetros, destacados na Tabela 1. Destes, foram extraídas duas configurações que contêm o menor RMSE médio e o maior R^2 máximo, respectivamente.

Hiper-parâmetros	Solver	Optimizer	Hidden Layers	Hidden Neurons	Alpha	Batch Size
Variáveis	relu, tanh	adam, lbfgs	1 - 4 camadas	1 - 36 neurônios	$1 \cdot 10^{-2}$, $1 \cdot 10^{-3}$, $1 \cdot 10^{-4}$	2 - 8

Tabela 1: Configurações dos Metaparâmetros utilizados na busca.

RESULTADOS E DISCUSSÕES

As redes MLP adam 5-24-1 e MLP lbfgs 5-7-1 apresentaram o menor RMSE médio de teste (0,8928) e o maior R^2 , respectivamente, com os hiperparâmetros otimizados: solver "relu", Batch size = 2 e Alpha = 0,01.

Os dois modelos podem ser comparados com os obtidos por HOSSAIN, 2012, na Tabela 2. A relação dos valores reais com os valores preditos se encontram na Figura 3.

Modelos	Treino			Teste		
	RMSE	MAPE	R^2	RMSE	MAPE	R^2
Eq. Teóricas	0.9343	42.0231	0.6432	1.3640	43.8840	0.3750
ANFIS	0.0001	0.0030	0.9999	1.1460	38.6050	0.4626
RSM	0.6306	27.7220	0.8085	0.9000	29.6120	0.6282
ANN	0.0007	0.0314	0.9999	0.9158	34.5351	0.6262
MLP (5-24-1)	0.3505	12.9345	0.9474	0.7353	49.4375	0.6158
MLP (5-7-1)	0.5161	19.0166	0.8717	0.5757	31.5747	0.8352

Tabela 2: Comparação estatística dos modelos de previsão.

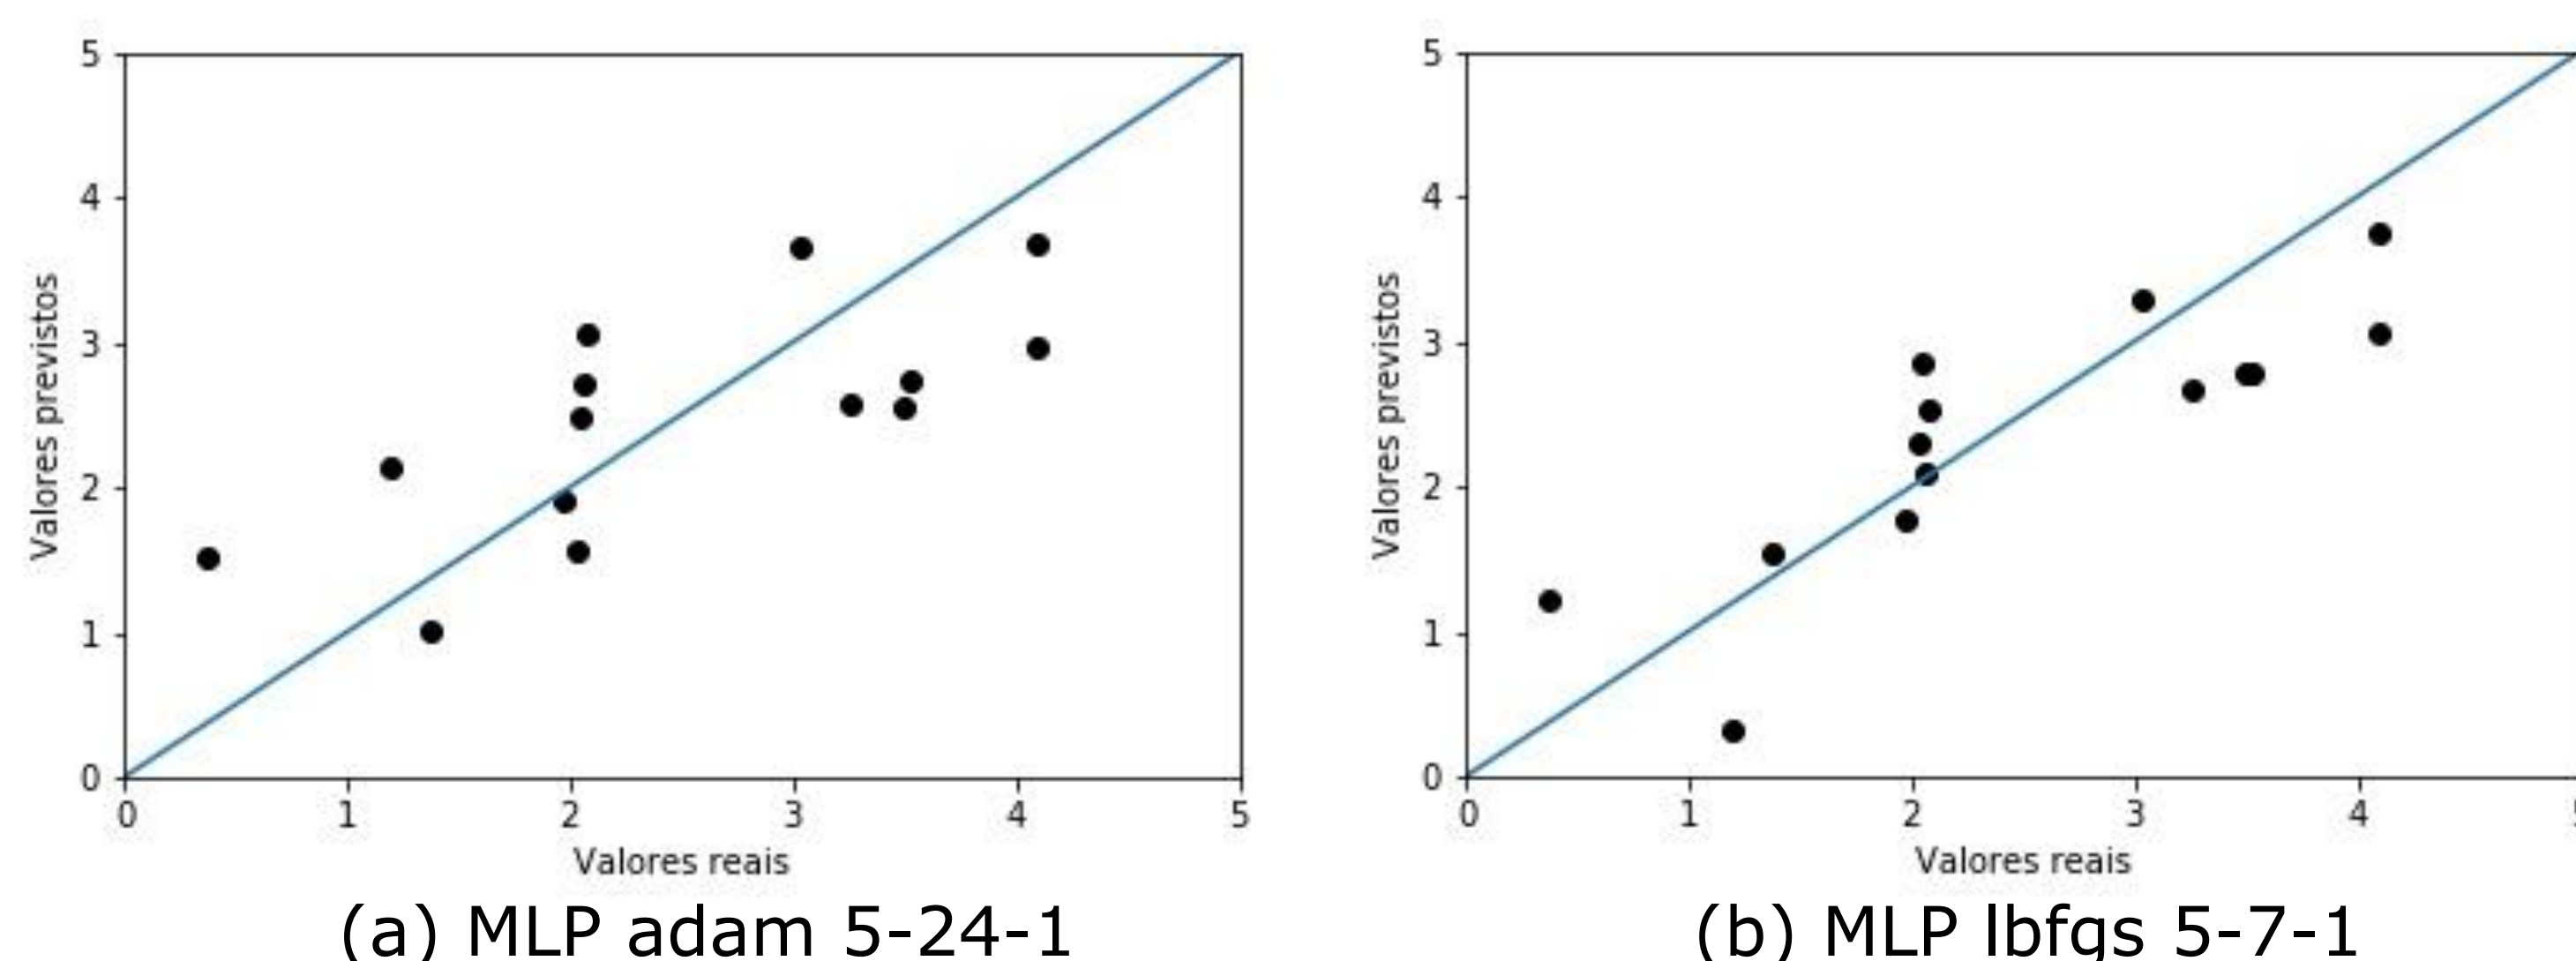


Figura 3: Valores de rugosidades superficiais reais versus valores preditos.

CONCLUSÕES

Os modelos obtidos neste trabalho complementaram com êxito os modelos anteriores, devido às novas tecnologias disponíveis na literatura. Um banco de dados maior para compor os dados de treinamento e de teste pode melhorar o desempenho do modelo em trabalhos futuros.

AGRADECIMENTOS

À todos que auxiliaram diretamente ou indiretamente para a realização deste trabalho.

REFERÊNCIAS

HOSSAIN, S. J. Artificial Intelligence Based Surface Roughness Prediction Modeling for Three Dimensional End Milling. International Journal of Advanced Science and Technology, Vol 45, 2012.

Apoio



IX Encontro de Iniciação Científica

XII Simpósio de Iniciação Científica da UFABC

14º Congresso de Iniciação Científica da USCS